

# Documento de Justificativa da Modelagem (Aprendizado Supervisionado)

## 1. Escolha do Algoritmo de Classificação

Para prever o atributo `Sucesso_Venda`, o algoritmo escolhido é o **Random Forest (Floresta Aleatória)**.

**Justificativa:** O Random Forest é um método ensemble (baseado em múltiplas árvores de decisão) altamente robusto e adequado para o conjunto de dados da Vinheria Agnello. A base contém uma mistura de variáveis categóricas (como `Produto`, `Canal_Venda` e `Regiao`) e numéricas (como `Valor_Total`, `Idade_Cliente` e `Lead_Time_Entrega`). O Random Forest lida nativamente com essa heterogeneidade sem exigir normalizações complexas. Além disso, o algoritmo é resistente a *overfitting* e fornece o cálculo de "Importância das Variáveis" (Feature Importance), o que permitirá ao negócio entender exatamente quais fatores mais impactam o fracasso ou sucesso de uma venda.

## 2. Explicação das Variáveis de Entrada (Atributos)

A modelagem será focada em prever comportamentos de compra e logística.

### Variável Alvo (Target):

- `Sucesso_Venda`: Variável categórica binária ("Sim" ou "Não") que representa a conclusão bem-sucedida da transação.

### Variáveis Preditoras (Features):

- `Canal_Venda`: Diferencia compras de E-commerce e Loja Física. É vital para o modelo, pois vendas na Loja Física possuem zero dias de entrega, alterando completamente a probabilidade de problemas logísticos.
- `Lead_Time_Entrega`: O tempo em dias até a entrega. Ao analisar os dados históricos, nota-se uma possível correlação onde tempos de entrega muito longos (como 18 a 20 dias) frequentemente coincidem com registros onde o sucesso da venda foi "Não".
- `Regiao`: Fator geográfico que impacta a infraestrutura de distribuição, especialmente em vendas online para áreas mais distantes.
- `Idade_Cliente` e `Valor_Total`: Indicam o perfil demográfico e o *ticket* da compra. Permitem que o modelo identifique se clientes de faixas etárias específicas ou compras de alto valor são mais sensíveis ao tempo de espera.
- `Produto`: O rótulo do vinho pode indicar padrões de engajamento do consumidor com diferentes safras ou tipos de bebida.

### Variáveis Descartadas:

- **ID\_Venda:** Por ser apenas um identificador único, não possui nenhum poder preditivo.
- **Data:** Para evitar ruídos e o viés de séries temporais não tratadas num modelo clássico de classificação, a data exata será desconsiderada.

### 3. Lógica de Separação entre Treino e Teste

A divisão do conjunto de dados seguirá a proporção de **80% para Treinamento e 20% para Teste**.

#### Estratificação (Stratified Split):

Observando o histórico, a grande maioria dos registros possui o **Sucesso\_Venda** marcado como "Sim". Como estamos lidando com um conjunto de dados desbalanceado (onde as falhas representam a classe minoritária), a separação utilizará amostragem estratificada. Isso garantirá que a exata proporção entre a classe "Sim" e a classe "Não" seja mantida tanto na base de treinamento quanto na de teste, impedindo que o algoritmo seja treinado sem exemplos suficientes de vendas malsucedidas.

### 4. Métricas Utilizadas para Avaliação do Modelo

Devido ao desbalanceamento das classes-alvo, a utilização da Acurácia de forma isolada pode gerar falsas impressões de desempenho. Portanto, o modelo será avaliado pelo seguinte conjunto de métricas:

- **F1-Score (Foco Principal):** Por ser a média harmônica entre a Precisão e o Recall, é a métrica mais confiável para bases desbalanceadas. Ela penalizará o modelo caso ele simplesmente aprenda a prever "Sim" para todas as vendas.
- **Recall (Sensibilidade) da classe "Não":** No contexto de negócios da Vinheria Agnello, identificar preventivamente as vendas que darão errado é crucial. O Recall avaliará, de todas as vendas que realmente falharam na vida real, quantas o modelo conseguiu detectar corretamente.
- **Precisão:** Medirá o grau de certeza do algoritmo. Quando o modelo classificar uma venda futura como "Não" (falha), qual a probabilidade de ele estar correto?
- **Matriz de Confusão:** Será gerada para visualizar de forma clara o volume absoluto de Falsos Positivos (prever que dará certo quando na verdade falha) e Falsos Negativos (prever falha para uma venda de sucesso).
- **Acurácia Geral:** Será documentada apenas como uma métrica de apoio para entender a taxa percentual de acertos globais do sistema.

