

Relatório Integrado de Ciência de Dados: Modelagem Preditiva e Analytics – Vinheria Agnello

1. Escolha do Algoritmo de Classificação

Para prever o atributo `Sucesso_Venda`, o algoritmo escolhido é o **Random Forest (Floresta Aleatória)**.

Justificativa: O Random Forest é um método ensemble (baseado em múltiplas árvores de decisão) altamente robusto e adequado para o conjunto de dados da Vinheria Agnello. A base contém uma mistura de variáveis categóricas (como `Produto`, `Canal_Venda` e `Regiao`) e numéricas (como `Valor_Total`, `Idade_Cliente` e `Lead_Time_Entrega`). O Random Forest lida nativamente com essa heterogeneidade sem exigir normalizações complexas. Além disso, o algoritmo é resistente a *overfitting* e fornece o cálculo de "Importância das Variáveis" (Feature Importance), o que permitirá ao negócio entender exatamente quais fatores mais impactam o fracasso ou sucesso de uma venda.

2. Explicação das Variáveis de Entrada (Atributos)

A modelagem será focada em prever comportamentos de compra e logística.

Variável Alvo (Target):

- `Sucesso_Venda`: Variável categórica binária ("Sim" ou "Não") que representa a conclusão bem-sucedida da transação.

Variáveis Preditoras (Features):

- `Canal_Venda`: Diferencia compras de E-commerce e Loja Física. É vital para o modelo, pois vendas na Loja Física possuem zero dias de entrega, alterando completamente a probabilidade de problemas logísticos.
- `Lead_Time_Entrega`: O tempo em dias até a entrega. Ao analisar os dados históricos, nota-se uma possível correlação onde tempos de entrega muito longos (como 18 a 20 dias) frequentemente coincidem com registros onde o sucesso da venda foi "Não".
- `Regiao`: Fator geográfico que impacta a infraestrutura de distribuição, especialmente em vendas online para áreas mais distantes.
- `Idade_Cliente` e `Valor_Total`: Indicam o perfil demográfico e o *ticket* da compra. Permitem que o modelo identifique se clientes de faixas etárias específicas ou compras de alto valor são mais sensíveis ao tempo de espera.
- `Produto`: O rótulo do vinho pode indicar padrões de engajamento do consumidor com diferentes safras ou tipos de bebida.

Variáveis Descartadas:

- **ID_Venda:** Por ser apenas um identificador único, não possui nenhum poder preditivo.
- **Data:** Para evitar ruídos e o viés de séries temporais não tratadas num modelo clássico de classificação, a data exata será desconsiderada.

3. Lógica de Separação entre Treino e Teste

A divisão do conjunto de dados seguirá a proporção de **80% para Treinamento e 20% para Teste**.



Estratificação (Stratified Split):

Observando o histórico, a grande maioria dos registros possui o **Sucesso_Venda** marcado como "Sim". Como estamos lidando com um conjunto de dados desbalanceado (onde as falhas representam a classe minoritária), a separação utilizará amostragem estratificada. Isso garantirá que a exata proporção entre a classe "Sim" e a classe "Não" seja mantida tanto na base de treinamento quanto na de teste, impedindo que o algoritmo seja treinado sem exemplos suficientes de vendas malsucedidas.

4. Métricas Utilizadas para Avaliação do Modelo

Devido ao desbalanceamento das classes-alvo, a utilização da Acurácia de forma isolada pode gerar falsas impressões de desempenho. Portanto, o modelo será avaliado pelo seguinte conjunto de métricas:

- **F1-Score (Foco Principal):** Por ser a média harmônica entre a Precisão e o Recall, é a métrica mais confiável para bases desbalanceadas. Ela penalizará o modelo caso ele simplesmente aprenda a prever "Sim" para todas as vendas.
- **Recall (Sensibilidade) da classe "Não":** No contexto de negócios da Vinheria Agnello, identificar preventivamente as vendas que darão errado é crucial. O Recall avaliará, de todas as vendas que realmente falharam na vida real, quantas o modelo conseguiu detectar corretamente.
- **Precisão:** Medirá o grau de certeza do algoritmo. Quando o modelo classificar uma venda futura como "Não" (falha), qual a probabilidade de ele estar correto?
- **Matriz de Confusão:** Será gerada para visualizar de forma clara o volume absoluto de Falsos Positivos (prever que dará certo quando na verdade falha) e Falsos Negativos (prever falha para uma venda de sucesso).
- **Acurácia Geral:** Será documentada apenas como uma métrica de apoio para entender a taxa percentual de acertos globais do sistema.



Abaixo está a resolução completa e detalhada da **Etapa 4: Reflexão Final**, estruturada exatamente para responder às perguntas críticas solicitadas, utilizando os dados textuais e métricas extraídos diretamente da modelagem da Vinheria Agnello:

Etapa 4: Reflexão Final

1. Quais insights foram descobertos a partir dos dados?

- **A Logística como Fator Crítico de Sucesso:** O gráfico de Importância das Variáveis (*Feature Importance*) revelou de forma contundente que o **Lead_Time_Entrega** é o atributo mais determinante para prever o desfecho de uma venda. Prazos de entrega muito extensos estão diretamente correlacionados a registros onde o **Sucesso_Venda** foi "Não".
- **Vantagem Operacional da Loja Física:** O canal de venda (**Canal_Venda**) possui um impacto significativo no modelo porque as compras realizadas presencialmente na Loja Física registram zero dias de tempo de entrega. Isso zera a probabilidade de ocorrência de problemas logísticos, garantindo uma taxa de sucesso substancialmente maior em comparação ao E-commerce.
- **Sensibilidade do Perfil de Compra:** As variáveis **Idade_Cliente** e **Valor_Total** figuram logo após as métricas logísticas em ordem de relevância. Isso indica que o comportamento de sucesso ou falha na venda também sofre influência demográfica e financeira, sugerindo que clientes de determinadas faixas etárias ou compradores de tickets mais elevados possuem maior sensibilidade ao tempo de espera.
- **Indiferença do Rótulo do Produto:** Os atributos específicos de cada vinho (**Produto**) apresentaram os menores índices de importância no modelo preditivo. Esse comportamento indica que o insucesso das vendas não está atrelado à rejeição ou preferência por um tipo de produto/safra, mas sim a falhas de caráter estritamente operacional e de distribuição.

2. Como a Vinheria poderia usar essa análise para tomar decisões estratégicas?

- **Otimização de Prazos e Parcerias no E-commerce:** Dado que o lead time de entrega é o maior detrator do sucesso comercial, a diretoria estratégica da Vinheria Agnello deve renegociar contratos com as transportadoras atuais ou buscar novos parceiros logísticos para o canal digital. O foco deve ser a redução drástica do tempo de envio, principalmente para as regiões Norte e Nordeste, que naturalmente enfrentam maiores desafios geográficos de infraestrutura.
- **Implementação de Alertas Preventivos no Checkout:** A empresa pode integrar o modelo de Random Forest diretamente ao sistema de vendas do site. Se no momento do fechamento do carrinho o sistema prever um risco de **Sucesso_Venda = "Não"** (com base em um lead time projetado longo para uma região distante), a Vinheria pode agir preventivamente oferecendo um upgrade automatizado para frete expresso gratuito ou priorizando a separação desse pedido no estoque.
- **Blindagem de Clientes de Alto Ticket:** Cruzando as informações de sensibilidade de **Valor_Total** e **Idade_Cliente**, a equipe de pós-venda pode criar um fluxo de atendimento prioritário e humanizado para compras de alto valor que estejam enfrentando atrasos logísticos, gerenciando as expectativas do consumidor antes que a insatisfação resulte em cancelamento.

3. O modelo de classificação teve bom desempenho? Quais melhorias poderiam ser feitas?

- **Análise Crítica do Desempenho:** Embora a Acurácia Geral do sistema possa parecer alta de forma isolada (~84% de acertos globais no teste), o desempenho real do modelo foi **insatisfatório** para o objetivo principal do negócio, que é identificar


preventivamente as vendas que darão errado.

- **Avaliação da Matriz de Confusão:** Olhando os dados absolutos da Matriz de Confusão do teste, constata-se que a base sofria de um forte desbalanceamento (com ampla maioria de classes "Sim"). Havia um total de 12 falhas reais no conjunto de teste (2 verdadeiros "Não" + 10 falsos "Sim"). Dessas 12 falhas, o modelo só conseguiu detectar corretamente **2 ocorrências**, falhando em prever **10 erros** (Falsos Positivos para sucesso).
- Isso resultou em um **Recall (Sensibilidade) para a classe "Não" de apenas 16,67%** (2/12). Além disso, de 8 vezes em que o modelo previu que uma venda falharia (2 verdadeiros "Não" + 6 falsos "Não"), ele esteve correto em apenas 2, gerando uma **Precisão de apenas 25%** e muitos alarmes falsos. O algoritmo simplesmente tendeu a classificar quase tudo como "Sim" para inflar a acurácia.


Melhorias Recomendadas:

1. **Tratamento Avançado do Desbalanceamento:** A separação estratificada preservou as proporções originais, mas não impediu o viés do algoritmo em direção à classe majoritária. Deve-se aplicar técnicas de reamostragem como o **SMOTE** (*Synthetic Minority Over-sampling Technique*) para gerar exemplos sintéticos da classe "Não" na base de treino, ou configurar o parâmetro interno `class_weight='balanced'` no Random Forest para penalizar severamente os erros na classe minoritária.
2. **Ajuste Fino de Hiperparâmetros (*Hyperparameter Tuning*):** Realizar uma busca estruturada (como *GridSearchCV* ou *RandomizedSearchCV*) para calibrar os parâmetros da floresta aleatória (ex: ajustar `max_depth`, `min_samples_leaf` e alterar o limiar de decisão de probabilidade de 0.5 para um nível que priorize o Recall da classe "Não").
3. **Experimentação de Outros Algoritmos:** Testar modelos baseados em comitês sequenciais de decisão (*Boosting*), tais como **XGBoost**, **LightGBM** ou **CatBoost**, que costumam apresentar resultados drasticamente superiores no aprendizado de padrões ocultos em bases tabulares altamente desbalanceadas e heterogêneas.
4. **Engenharia de Recursos (*Feature Engineering*):** Reintroduzir componentes derivados da variável `Data` que foi descartada (como o dia da semana, mês ou proximidade de datas comemorativas/feriados), além de criar novas variáveis preditoras, como a distância exata em quilômetros até a região de destino, fornecendo insumos mais ricos para o aprendizado do classificador.

Vendas por Produto



Mapa de Vendas por Região



KPI Taxa de Sucesso

